UID v1.0

*by **digi_cs** Jul-Oct 2024* *cosmogen@gmail.com*

Куда я вас веду?
В галактику Андромеды.

Данная библиотека предоставляет сервис для генерации UID (Unidue ID) - уникальных строк с контролируемой структурой.

Уникальные строки в AWK могут иметь множество применений из которых важнейшим является их **использование в качестве указателей**.

Указатели являются **наиболее мощным способом адресации** данных в AWK..

Каждый указатель может адресовать **неограниченное количество массивов и строк** располагаемых в глобальных массивах-полях по индексу его строки:

```
ARRAY[ ptr ]
```

Применение указателей выводят язык AWK на совершенно новый качественный уровень открывая в этом языке программирования **новые измерения и возможности**. Фактически можно говорить о новом типе данных с которым умеет работать AWK: **указателях**.

Смотрите раздел **POINTERS IN AWK**.

Также данная библиотека включает в себя реализацию **HID** (Hidden ID) — совершенно необходимого в программировании на AWK ресурса особенно (но не только) в части работы с массивами (смотрите раздел **HIDs IN AWK**).

Библиотека протестирована и полностью работоспособна для обычного и байтового (-b) режимов gawk.

USE

Для использования выполните:

```
@include    "uid.lib"
```

В библиотеке реализована **динамическая инициализация**. Это означает что ресурсы библиотеки можно вызывать **из любых точек кода** (в т.ч. и из BEGIN{}-зон файлов включаемых в общий исходник ранее — до инклуда данной библиотеки).

Инициализация библиотеки **произойдёт автоматически** в момент первого вызова любой из её функций, но не позднее выполнения BEGIN{}-зоны данной библиотеки.

UID

Уникальные строки (**uid**) генерируются с помощью объявляемых **uid-генераторов**.

При объявлении uid-генератора - ему передаются параметры определяющие содержимое генерируемых этим генератором строк (т. е. определяющие то, из чего они будут состоять).

Адресуются uid-генераторы с помощью указателй — любой строки.

Общая структура генерируемых уникальных строк показана ниже:

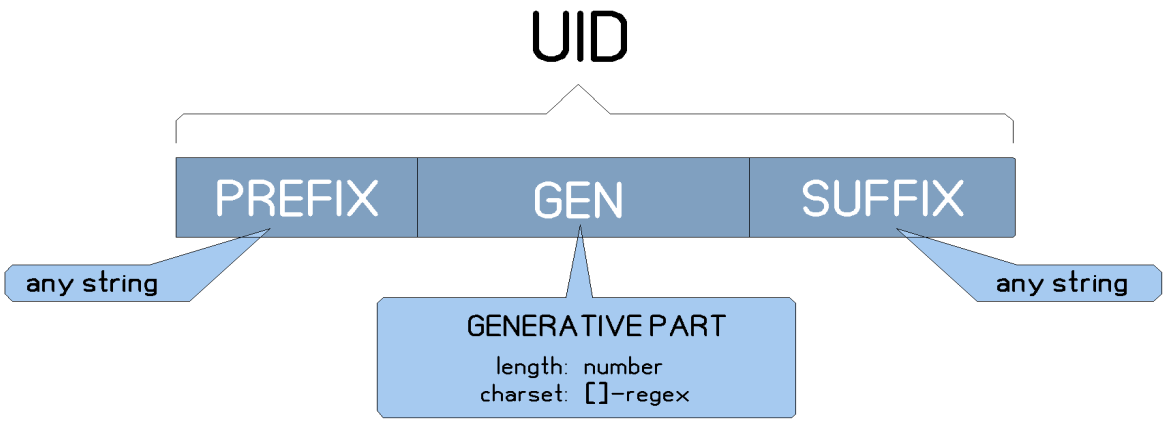

Diagram 1

Префикс и суффикс добавляются соответственно слева и справа к генеративной части uid которая может быть любой длины (length) и состоять из перебора символов указываемых параметром charset.

. Чтобы **сгенерировать уникальную строку** с помощью некоторого объявленого ранее **uid-генератора** вызывается функция:

`uid::get``( ptr )`

где: *ptr* – указатель на uid-генератор с помощью которого производится генерация строки

PERFORMANCE: **5.7 Muid/sec** for **i7/2Ghz**

Для того чтобы **объявить независмый uid-генератор** вызывается функция:

uid::set(*ptr*, *prefix*, *suffix*, *length*, *charset*)

```
example:

      ptr = "Gen1"

      uid::set( ptr, "<", ">", 3, "01" )

      ...
```

Объявляется uid-генератор с указателем "**Gen1**" имеющий префикс "**<**", суффикс "**>**" и генеративную часть из **трёх** символов из числа: "**0**" и "**1**".

… и теперь начинаем генерировать с помощью объявленного uid-генератора строки:

```
      ...

      while ( 1 )

            print ++CNT ":\t" uid::get( ptr )

outputs:

      1:    <000>
      2:    <001>
      3:    <010>
      ...
      7:    <110>
      8:    <111>

      fatal: uid::get( Gen1 ): out of uid range
```

Символы в генеративной части uid перебираются инкрементально также как это делают цифровые разряды в числах.

При выборе всех возможных комбинаций символов возникает фатальная ошибка.

> Параметр *charset* подаётся в виде строки: []-фрагмента регулярного выражения соответствующего тем символам которые разрешены для применения в генеративной части uid. При этом выбор символов (из которых выбирает данное регулярное выражение) ограничен символами в диапазоне: \x00-\xFF.

> Параметр *charset* может быть не указан (== ""). в этом случае значением по-дефолту станет: "**\xC0-\xEF**"- что соответствует 48ми символам с hex-кодом: от C0 до EF.

> Параметр *length* определяет количество символов в генеративной части uid-генератора. **оно может быть любым** >= 1.

> Параметр *length* может быть не указан (== ""). в этом случае значением по-дефолту станет: **4**

UID-GENERATOR

Character set представляет собою список-массив перечисляющий последовательно все возможные комбинации которые данный character set может вернуть.

В зависимости от необходимости charset список-массив может содержать в себе как список всех возможных **одиночных** символов (например при нечётном length), так и все комбинации **двух** таких-же возможных символов (например при length > 1)

Ниже приведён пример одиночного и двойного charset список-массива:

```
single character set list array for characters: "A-C"

      [ "" ] = "A"
      [ "A" ] = "B"
      [ "B" ] = "C"
      [ "C" ] = - (undefined)

double character set list array for characters: "01"

      [ "" ] = "00"
      [ "00" ] = "01"
      [ "01" ] = "10"
      [ "10" ] = "11"
      [ "11" ] = -
```

Uid-генератор имеет **два character set**: low и high и два счётчика _COUNTL и _COUNTH соответственно - содержащие последние значения полученые от character set

Таким образом осуществляется перебор 1-4 символов для генеративной части uid.

Если length превышает значение 4, то используются «надстроенные» uid-генераторы — не имеющие собственного префикса и суффикса, но по сути — повторяющие структуру тех-же «объявляемых» uid-генераторов.

В зависимости от length создаётся нужное количество таких “надстраиваемых» uid-генераторов из расчёта: один uid-генератор на каждые следующие 1-4 символа в генеративной части uid.

Ниже показана структура uid-генератора:

UID-GENERATOR STRUCTURE

```
                    namespace uid

  _PREFIX[ ptr ]                    = "prefix"
  _SUFFIX[ ptr ]                    = "suffix"
_COUNTPTR[ ptr ]                    = countptr
_CHARSETL[ ptr ]                    = charsetptr
_CHARSETH[ ptr ]                    = charsetptr

  _COUNTL[ countptr ]               = last returned low-part
  _COUNTH[ countptr ]               = last returned hi-part

   _NEXT[ countptr ]                = ptr to next uid-generator
  _HIPFX[ countptr ]                = last uid returned from the
                                    next uid-generator

_CHARSET[ charsetptr ][ ... ]       character set list-array
```

Обратите внимание что поля _COUNTL, _COUNTH, _NEXT и _HIPFX находятся не по указателю ptr, а по указателю countptr который хранится в поле _COUNTPTR[ptr].

И также младший и старший character set: они не привязаны к ptr, они привязаны к указателям charsetptr хранящихся в полях _CHARSETL[ptr] и _CHARSETH[ptr] соответственно.

Из этого можно вывести для понимания тот важный момент что и счётчики _COUNTL/_COUNTH и младший/старший character set могут быть у uid-генератора удалёнными — т. е. чьими-то ещё (от какого-то другого uid-генератора).

И этот факт выводит на идею о двух дополнительных режимах в которых помимо основного (независимого) может быть синициализирован uid-генератор.

Первый режим это когда uid-генератор использует удалённые (чьи-то) character set, но при этом имеет свои собственные префикс и суффикс, а главное - собственные счётчики перебора символов в character set (т. е. ведёт собственный отсчёт комбинаций в генеративной части генерируемых строк, но при этом использует чужую генеративную часть как образец: та-же длина и из тех-же символов)

Такой uid-генератор будет генерировать уникальные строки с собственным префиксом и суффиксом и иметь генеративную часть полностью аналогичную удалённому uid-генератору от которого используется character set, но при этом имея собственную последовательность перебора символов в генеративной части

Для установки uid-генератора в этом режиме называемом режимом **удалённого character set**, используется функция:

uid::setcs(*ptr*, *prefix*, *suffix*, *charsetptr*)

```
example:

      ptr1 = "Gen1"
      ptr2 = "Gen2"

      uid::set( ptr1    , "<", ">", 3, "01" )

      uid::setcs( ptr2  , "[", "]", ptr1 )

      ...
```

Объявляется uid-генератор с указателем "Gen1" имеющий префикс "<", суффикс ">" и генеративную часть из трёх символов из числа: "0" и "1".

Обявляется uid-генератор с указателем "**Gen2**" имеющий префикс "**[**" суффикс "**]**" и генеративную часть аналогичную генеративной части uid-генератора "Gen1" (т. е. имеющую ту-же длину (**3**) и состоящая из тех-же символов: **0** и **1**).

… и теперь начинаем генерировать с помощью обоих объявленых uid-генераторов строки:

```
      ...

      while ( 1 ) {

            print ++CNT ":\t" ptr1 "\t" uid::get( ptr1 )

            print   CNT ":\t" ptr2 "\t" uid::get( ptr2 ) }

      outputs:

            1:    Gen1  <000>
            1:    Gen2  [000]
            2:    Gen1  <001>
            2:    Gen2  [001]
            ...
            7:    Gen1  <110>
            7:    Gen2  [110]
            8:    Gen1  <111>
            8:    Gen2  [111]

            fatal: uid::get( Gen1 ): out of uid range
```

> Параметр *charsetptr* может быть не указан (== "") и в этом случае будет взят указатель на **дефолтовый uid-генератор**.

Ещё одним из возможных режимов uid-генератора является режим когда и character set и счётчики _COUNTL/_COUNTH uid-генератора удалённые (т. е. не свои, а от какого-то другого uid-генератора)

Такой uid-генератор будет генерировать уникальные строки с собственным префиксом и суффиксом, но при этом будет иметь генеративную часть генерируемую другим uid-генератором.

Для установки uid-генератора в этом режиме называемом режимом **разделённого character set** используется функция:

uid::setcnt(*ptr*, *prefix*, *suffix*, *countcharsetptr*)

```
example:

      ptr1 = "Gen1"
      ptr3 = "Gen3"

      uid::set( ptr1    , "<", ">", 3, "01" )

      uid::setcnt( ptr3 , "{", "}", ptr1 )

      ...
```

Объявляется uid-генератор с указателем ”Gen1” имеющий префикс ”<”, суффикс ”>” и генеративную часть из трёх символов из числа: ”0” и ”1”.

Обявляется uid-генератор с указателем ”**Gen3**” имеющий префикс ”**{**” суффикс ”**}**” и генеративную часть от uid-генератора ”Gen1” (т. е. именно её, а не её аналог)

… и теперь начинаем генерировать с помощью обоих объявленых uid-генераторов строки:

```
      ...

      while ( 1 ) {

            print ++CNT ":\t" ptr1 "\t" uid::get( ptr1 )

            print ++CNT ":\t" ptr3 "\t" uid::get( ptr3 ) }

      outputs:

            1:    Gen1  <000>
            2:    Gen3  {001}
            3:    Gen1  <010>
            4:    Gen3  {011}
            5:    Gen1  <100>
            6:    Gen3  {101}
            7:    Gen1  <110>
            8:    Gen3  {111}

            fatal: uid::get( Gen1 ): out of uid range
```

> Параметр *countcharsetptr* может быть не указан (== "") и в этом случае будет взят указатель на **дефолтовый uid-генератор**.

При установке uid-генераторов в режимах удалённого или разделённого character set можно ссылаться не только на независимо объявленные uid_генераторы, но и на такие-же uid-генераторы — работающие в режимах удалённого либо разделённого character set.

PREDEFINED UID-GENERATORS

Библиотека предоставляет два предустановленых uid-генератора: дефолтовый и hid-генератор.

Оба предустановленых uid-генератора нельзя отменить или переобъявить..

Все другие uid-генераторы могут быть свободно переобъявлемы в любом режиме.

DEFAULT UID-GENERATOR

указатель: "" (пустая строка)

Дефолтовый uid-генератор генерирует строки со следующей структурой:

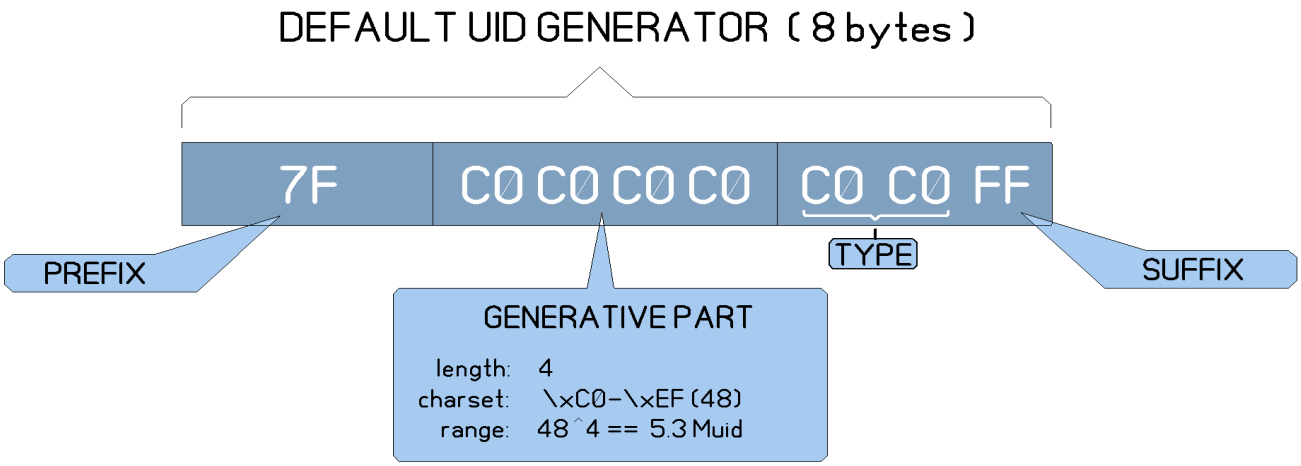

Diagram 2

```
uid::set( "", "\x7F", "\xC0\xC0\xFF", 4, "\xC0-\xEF" )
```

Дефолтовый uid-генератор необходим библиотеке для нормального функционирования и не может быть отменён или переобъявлен.

Смотрите раздел **POINTERS IN AWK**.

HID-GENERATOR

указатель: ”hid”

Hid-генератор генерирует строки со следующей структурой:

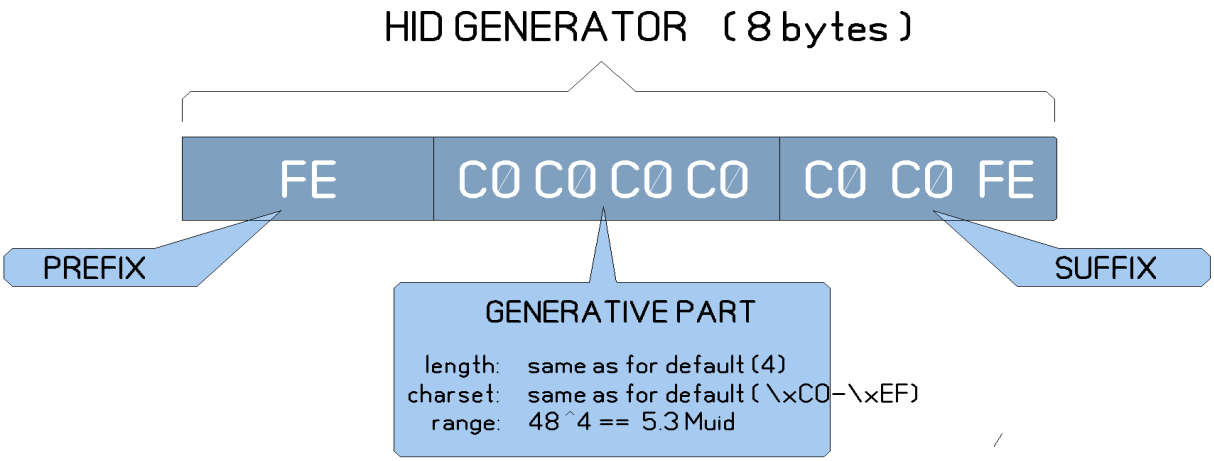

Diagram 3

```
uid::setcs( "hid", "\xFE", "\xC0\xC0\xFE" )
```

HIDs IN AWK

Hid является **очень важным ресурсом** программирования в AWK.

Всякий раз когда вы собираетесь **сохранить** в некотором **массиве** какие-то сторонние **данные** — вы вынуждены раз за разом придумывать ответ на один и тот-же вопрос: **под какими индексами** это делать?

Действительно, ведь в массиве находятся некоторые **«рабочие» индексы** — нам крайне необходимо чтобы «служебные» индексы никак **не конфликтовали** с возможными «рабочими» индексами.

И если мы просто, допустим, будем указывать «служебные» индексы **прямой строкой**:

```
A[ "LIST" ]
```

… то по понятным причинам мы очень быстро на такой **конфликт** как раз и нарвёмся.

Важным также остаётся и **читабельность кода**: если вы начнёте усложнять строку индекса в массиве какими-то дополнительными символами - чтобы минимизировать вероятность **возможных конфликтов** с рабочими индексами — то вы неизбежно потеряете её в читабельности:

```
A[ "\xFELIST\xFE" ]
```

Возникает **замкнутый круг**: мы хотим предельно **ясной записи индекса**, но такая запись может вступить в **конфликт с рабочими индексами**. Если-же мы будет усложнять индекс, то неизбежно будем терять в комфорте.

HID является системным решением данной проблемы.

Hid — это глобальная переменная - называемая «**несущей**» - которая **объявляется с помощью функции hid**() и которой присваивается так называемое **сильное значение** генерируемое **hid-генератором**.

Суть присваемого hid-переменной значения заключается в том, **чтобы не быть похожим ни на что** — ни на возможные данные, ни на возможные «рабочие» индексы в массивах.

Пользователь может активно использовать несущие hid-переменные как своего рода **«служебные» индексы** в массивах - для доступа к какой-либо дополнительной, сопутствующей информации сохраняемой **внутри массива**:

```
A[ SOME_ ]      вместо:      A[ "SOME_" ]
```

ВАЖНО! Негативным фактором при использовании hid является тот факт, что если **hid переменная не объявлена** или её **имя написано с ошибкой** - то **пользователь об этом никак прямо не узнает** и код начнёт выполнять **непредсказуемые действия** (необъявленная переменная будет возвращать пустую строку вместо специального значения).

Поэтому следует **внимательно относится к написанию hid** в коде и следить за тем чтобы **все используемые hid были предварительно объявлены**.

Некоторые служебные индексы которые нам понадобятся: - локальные: т. е. **внутренние в указанном namespace**. А некоторые, нужны такие, чтобы в любом namespace объявлялись **одним и тем-же значение**(глобальные).

Объявления hid должны производится **в полном объёме в каждом namespace** где они используются.

Так называемые **суперглобальные hid** – несущими переменными которых являются суперглобальные переменнные — также **обязательны для объявления в каждом namespace** в которых они используются.

Объявление hid производится с помощью **присваивания несущей hid-переменной результата возвращаемого функцией hid() вызванной со строкой имени объявляемого hid в качетсве параметра**:

hid::get(*name*, *code*)

```
example:

      SOME_ = hid::get( "SOME_" )

      print hexdump( SOME_ )

outputs (например):

      FE C0 C1 C2 C3 C4 C5 FE
```

Объявляется **hid** с именем: *name*. Несущей hid-переменной *name* присваивается некоторое специальное значение.

Параметр *code* позволяет пользователю произвести **объявление hid** используя собственное **специальное значение**. Если ***code*** != «», то оно становится **новым специальным значением**. В противном случае специальное **новое значение** будет сгенерированно **hid-генератором**.

В некоторых случаях пользователю просто нужно **специальное значение**, но не нужна его регистрация как hid:

> Если параметр *name* равен **пустой строке** (== “”), то функция hid() просто **возвращает новое специальное значение**:

```
      ... = hid::get()
```

Параметр *name* содержит имя объявляемого hid. Имя может быть дано с указанием namespace или без него. В качестве **namespace-разделителя** можно использовать '**::**' или '.'

Если hid *name* до этого момента объявлен не был, то функция hid() **вернёт новое специальное значение** и **сохранит** его в ассоциации с *name* .

При дальнейших попытках объявления того-же *name* функция hid::get() будет просто **возвращать сохранённое значение**.

> Если *name* не содержит **namespace-разделителя**, то производится **объявление глобального hid**:

```
GLOBAL_     = hid::get( "GLOBAL_" )
```

Глобальный hid в любом namespace несёт одно и то-же значение.

```
@namespace = "one"

BEGIN{

      GLOBAL_ = hid::get( "GLOBAL_" )

@namespace "two"

BEGIN{

      GLOBAL_ = hid::get( "GLOBAL_" )

# one::GLOBAL_ == two::GLOBAL_
```

> Если параметр *name* содержит **namespace-разделитель**, то производится **объявление локального hid**:

```
@namespace "some"

BEGIN{

      LOCAL_ = hid::get( "some::LOCAL_" )
```

Локальный hid объявляется только для своего namespace и всегда несёт своё собственное значение.

> Если в параметре *name* **не указывается namespace**, то используется тот namespace, который **указывался функции** hid::get() **последним**:

```
@namespace "some"

BEGIN{

      LOCAL1_ = hid::get( "some.LOCAL_" )

      LOCAL2_ = hid::get( ".LOCAL2_" )
```

HID[]

Для того чтобы понять является-ли некоторая строка одним из «служебных» индексов пользователь может применять проверку эксистенса этой строки в качестве индекса в суперглобальном массиве HID.

Например внутри for-in цикла:

```
for ( i in A )
      if ( i in HID )
            continue
      else ...
```

Суперглобальный массив **HID** содержит в качестве индексов все специальные значения присвоенные hid.

hid::name(*code*)

Параметр *code* должен быть значением одной из объявленых несущих hid-переменных.

Если *code* не является таким значением, то функция вовзвращает **null**.

Функция возвращает имя hid с кодом *code*.

example:

```
BEGIN{
      GLOBAL_           = hid::get( "GLOBAL_" )
      some::LOCAL1_     = hid::get( "some::LOCAL1_" )
      LOCAL2_           = hid::get( ".LOCAL2_" )

      print hid::name( GLOBAL_ ) "'"
      print hid::name( some::LOCAL1_ ) "'"
      print hid::name( LOCAL2_ ) "'" }
```

outputs:

```
GLOBAL_'
some::LOCAL1_'
some::LOCAL2_'
```

HID: **LIST**

LIST = **hid::get**(“*LIST*”)

Массив (A) в AWK может представлять собою список уникальных айтемов с неопределённой последовательностью.

Для того чтобы ввести в AWK понятие массива с заданой последовательностью его индексов (айтемов) - необходимо перечислить эту последовательность в подмассиве A[LIST] в виде простейшего списка:

Элемент «» (пустая строка хранит индекс первого айтема в списке.

```
# items of A: first, next and last:

A[ LIST ][ “” ] = “first”
          [ “first” ] = “next”
          [ “next” ] = “last”
          [ “last” [ = “”
 [ “first” ]...
 [ “next” ]...
 [ “last” ]...
```

Таким образом вместо for-in цикла для массива A мы используем:

```
i = “”

while ( “” != i = A[ LIST ][ i ] )

      # process A[ i ]
```

или

```
for ( i = “”; “” != i = A[ LIST ][ i ]; )

      # process A[ i ]
```

При этом мы по-прежнему можем работать с основным массивом в цикле for-in — с одной оговоркой:

```
for ( i in A )
      if ( i in HID )
            continue          # this is hid (LIST)
      else
            # process A[ i ]
```

Обратите внимание что последний элемент в списке следует создавать в массиве — так вы сможете гарантированно точно определять количество айтемов в списке:

```
number = length( A[ LIST ] ) - ( "" in A[ LIST ] )
```

в случае если требуется двунаправлеый список то, в подмассиве A[LIST] создаётся ещё один подмассив A[LIST][LIST] - в котором айтемы перечисляются в обратной последовательности, а элемент A[LIST][LIST][""] хранит индекс последнего айтема в списке:

```
A[ LIST ][ "" ] = "first"
          [ "first" ] = "next"
          [ "next" ] = "last"
          [ "last" [ = ""
          [ LIST ][ "" ] = "last"
                  [ "first" ]= ""
                  [ "next" ]= "first"
                  [ "last" ]= "next"
 [ "first" ]...
 [ "next" ]...
 [ "last" ]...
```

Для поддержки двунаправленных списков формула вычисления количества айтемов в списке будет:

```
number = length( A[ LIST ] ) - ( "" in A[ LIST ] + LIST in A[ LIST ] )
```

POINTERS IN AWK

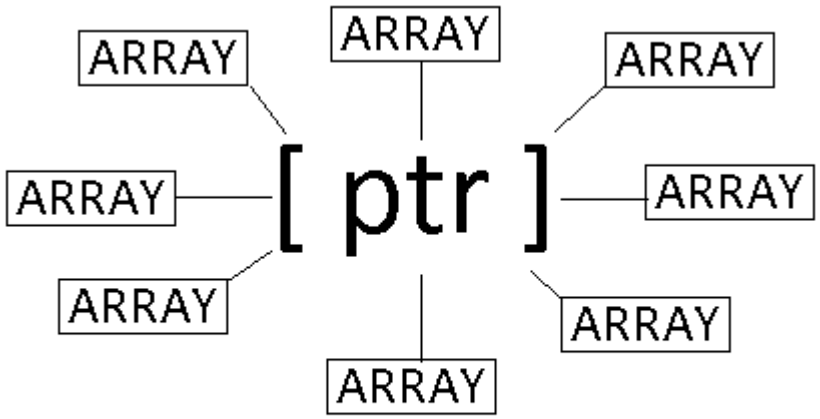

object in AWK

Для лучшего понимания того, как использовать указатели в AWK рекомендуется прежде всего ознакомиться с исходным кодом самой библиотеки:

- вы увидите как следует располагать данные относительно указателя:

```
FIELD[ ptr ]
```

Например: некоторый указатель *ptr* имеет обязательное свойство: ID располагаемый в:

```
ID[ ptr ]
```

– как узнать: является-ли *ptr* указателем:

Для определения является-ли строка *ptr* **действующим указателем** необходимо выполнить:

```
if ( ptr in ID )

      # ptr указатель

else  # ptr что-то другое
```

Тела указателей имеют характерную структуру легко распознаваемую с помощью регулярных выражений среди данных: каждый указатель начинается с символа **\x7F** и затем через 6 байт, заканчивается символом **\xFF**.

Таким образом «`что-то другое`» - в примере выше - может означать что строка *ptr* это любая другая строка состоящая из данных и указателей.

Суть предлагаемой методики работы с данными состоит в том, что исходная строка для нас: это смесь данных и указателей.

Для поиска указателей любого типа предлагается использовать регулярное выражение:

```
/\x7F......\xFF/
```

Если искать надо указатели конкретного типа(ов), то следует указывать возможные символы в поле типа искомого указателя (два предпоследних байта в указателе — см. ***Diagram 2***):

```
/\x7F....\xT0\xT1\xFF/
```

где: **\xT0** и **\xT1** – символы-идентификаторы типа (класса) искомого указателя

Для того, чтобы «не наехать» каким-либо сторонним регулярным выражением на тела указателей лежащих среди данных следует избегать символа **\x7F** (при движении вправо) и символа **\xFF** (при движении влево).

FYI

Uid-генераторы в моём энвайременте также используются для генерации имён временных файлов

Настоятельно не советую экспериментировать с настройками дефолтового и hid генераторов: поверьте, взятые на вооружение структуры генерируемых ими строк — взяты не с потолка или откуда-нибудь. Для меня лично они являются указателями уже третьего поколения.

ПЕРСПЕКТИВЫ

На первом этапе нам необходимо поднять общий уровень базовой техники программирования в AWK.

Данная библиотека относится к базовой технике программирования на AWK

Следующим релизом станет библиотека ARR — для работы с массивами (также базовая техника).

Затем последует релиз библиотеки CLASS – представляющая из себя классовую имплементацию для AWK: основы базовой техники и описание приёмов ООП в AWK.

Гипотетический план публикаций библиотек для AWK на 2024-2025 год:

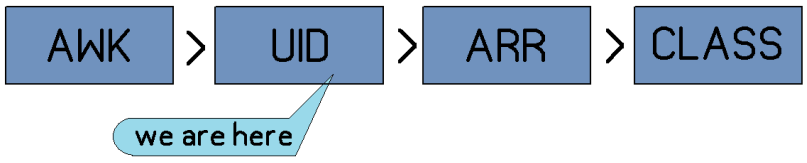

AUTHOR

Классовая имплентация в AWK является ключевым моментом для дальнейшего всестороннего развития этого языка.

Моя личная «галактика Андромеды» находится в области работы с комплексным регулярным выражением, и именно туда я вас веду.

Благодарю Вас за интерес и за Ваше внимание!

That's all folks! :)

Kind Regards
Denis Shirokov

RESPECT DUE

All awkers from all the world!

gawk Team